IA e Bancos de Dados: Administrando Informação com Inteligência e Responsabilidade

Aluna : Pamella Moreira de Carvalho

Atenção: Foi utilizado Chat GPT para a formatação deste relatório

---

Diagnóstico dos Problemas

O cenário proposto apresenta desafios relacionados ao desempenho, segurança e integração de diferentes tecnologias de banco de dados utilizadas por uma startup de recomendação inteligente. No PostgreSQL, a principal dificuldade observada é a lentidão na geração de relatórios, impactando diretamente o SLA de 500 ms estabelecido para os dashboards. Esse problema pode estar relacionado à ausência de índices adequados nas colunas mais utilizadas em filtros e ordenações, bem como à execução de consultas com varreduras completas de tabelas (Sequential Scan) e operações de agregação custosas. No MongoDB, os riscos identificados envolvem a inexistência de uma estratégia formal de backup e a utilização de usuários com permissões excessivas, aumentando a probabilidade de perda de dados e acessos indevidos. Já no Qdrant, as falhas de integração estão associadas à ingestão de embeddings com dimensões incorretas e à falta de padronização dos payloads, dificultando a consistência dos dados utilizados nos processos de busca semântica e sistemas RAG (Retrieval-Augmented Generation).

Soluções Aplicadas

Para melhorar o desempenho do PostgreSQL, foi proposta a utilização do comando EXPLAIN ANALYZE para identificar gargalos nas consultas críticas e validar oportunidades de otimização. Em seguida, foram criados índices compostos sobre os campos mais utilizados nos filtros e ordenações, especialmente nas colunas status e order_date da tabela de pedidos. Também foi considerada a utilização de materialized views para relatórios recorrentes, reduzindo a necessidade de processamento repetitivo. No MongoDB, as medidas adotadas incluíram a criação de usuários seguindo o princípio do menor privilégio (Least Privilege), separando perfis de leitura e escrita, além da implementação de rotinas de backup utilizando mongodump e procedimentos de restauração com mongorestore. Para o Qdrant, foi definida uma padronização da geração de embeddings utilizando um único modelo de linguagem, garantindo consistência na dimensão dos vetores. Também foi estabelecido um esquema padronizado de payload contendo identificadores, texto, categoria, idioma, versão do embedding e timestamp, permitindo melhor rastreabilidade e interoperabilidade dos dados. A Inteligência Artificial Generativa foi utilizada como ferramenta de apoio para sugerir otimizações SQL, elaborar checklists de segurança e propor estruturas de integração entre os bancos de dados, sempre com validação e adaptação humana das recomendações recebidas.

Segurança, Privacidade e LGPD

A proteção das informações foi tratada de acordo com os princípios da Lei Geral de Proteção de Dados (LGPD), especialmente os conceitos de finalidade, necessidade, minimização e transparência. Foram adotadas medidas de controle de acesso por meio de perfis de usuários específicos para cada função, reduzindo a exposição de dados sensíveis. Além disso, recomenda-se a utilização de criptografia em trânsito por meio de TLS/SSL e criptografia em repouso nos ambientes de armazenamento. Para ambientes de testes e homologação, os dados devem passar por processos de anonimização ou mascaramento, evitando a utilização de informações pessoais reais. A estratégia de backup inclui

rotinas periódicas de cópia e testes de restauração para garantir a recuperação dos dados em situações de falha. Também foram previstos mecanismos de auditoria e geração de logs para registrar quem acessou os sistemas, quando o acesso ocorreu e quais operações foram realizadas, fortalecendo a rastreabilidade e a conformidade regulatória.

Integração Inteligente dos Bancos de Dados

A integração entre PostgreSQL, MongoDB e Qdrant foi estruturada por meio de um fluxo de processamento de dados semelhante a um pipeline ETL. Os dados transacionais relacionados a clientes, pedidos e produtos permanecem armazenados no PostgreSQL, responsável pelas operações críticas de negócio. As avaliações dos usuários são registradas no MongoDB devido à flexibilidade oferecida para armazenar textos livres e metadados variados. Em seguida, essas avaliações passam por um processo de limpeza e transformação, onde são gerados embeddings utilizando um modelo padronizado de linguagem. Os vetores resultantes são armazenados no Qdrant juntamente com payloads consistentes e versionados. Quando um sistema de recomendação ou busca semântica é acionado, ele consulta simultaneamente os dados estruturados do PostgreSQL e os vetores do Qdrant, combinando informações transacionais e contextuais para fornecer resultados mais relevantes. Para garantir a consistência entre os ambientes, foram definidos padrões únicos de identificação, timestamps sincronizados e métricas de observabilidade capazes de monitorar latência, qualidade dos dados e desempenho das consultas.

Prompts de IA Utilizados e Aplicações

Prompt 1 – Otimização SQL: “Tenho uma consulta que agrega faturamento dos últimos 30 dias utilizando as tabelas orders, order_items e products. Os filtros são status='paid' e order_date >= NOW()-30 dias. Sugira índices compostos e possíveis reescritas para reduzir custo e melhorar desempenho.”

Contribuição incorporada: recomendação da criação de índices compostos sobre status e order_date, além da análise do plano de execução por meio do EXPLAIN ANALYZE.

Prompt 2 – Segurança MongoDB e LGPD: “Liste controles mínimos de segurança para MongoDB em ambiente de produção com foco em menor privilégio, backup, auditoria e conformidade com a LGPD.”

Contribuição incorporada: criação de usuários com permissões específicas, definição de rotinas de backup, uso de criptografia e implementação de mecanismos de auditoria.

Prompt 3 – Integração Vetorial com Qdrant: “Proponha um esquema padronizado de payload e um fluxo ETL simplificado para inserir avaliações de clientes em uma base vetorial utilizando embeddings de 384 dimensões.”

Contribuição incorporada: padronização dos campos review_id, text, source, lang, embedding_model, embedding_dim e timestamp, além da recomendação de validação prévia dos vetores antes da ingestão.

Conclusão

A utilização combinada de PostgreSQL, MongoDB e Qdrant permite construir uma arquitetura moderna capaz de integrar dados estruturados, documentos textuais e informações vetoriais em um único ecossistema inteligente. A aplicação das otimizações propostas contribui para melhorar o desempenho das consultas, fortalecer a segurança da informação e garantir conformidade com a LGPD. Além disso, a integração entre os três bancos possibilita a implementação de mecanismos avançados de recomendação e busca semântica, agregando valor ao negócio sem a necessidade de aumento imediato de infraestrutura. O uso de Inteligência Artificial Generativa mostrou-se um importante recurso de apoio à tomada de decisão técnica, desde que suas sugestões sejam analisadas e validadas por profissionais responsáveis pela solução.